ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN – CƠ – TIN

BÁO CÁO CUỐI KỲ

Các phương pháp ngẫu nhiên và ứng dụng

Đề tài:

ỨNG DỤNG XÍCH MARKOV TRÊN TRẠNG THÁI RFM ĐỂ PHÂN KHÚC VÀ DỰ BÁO GIÁ TRỊ VÒNG ĐỜI KHÁCH HÀNG TRONG THƯƠNG MẠI ĐIỆN TỬ

Giảng viên hướng dẫn: PGS.TS. Tạ Công Sơn

Học viên thực hiện: Cao Duy Khánh - 25007876

Hà Nội, tháng 8 năm 2026

MỤC LỤC

CHƯƠNG 1: GIỚI THIỆU 5
1.1. Bối cảnh và động lực nghiên cứu 5
1.2. Vấn đề nghiên cứu 5
1.3. Mục tiêu và câu hỏi nghiên cứu 6
1.4. Đối tượng và phạm vi nghiên cứu 7
1.4.1. Đối tượng nghiên cứu 7
1.4.2. Phạm vi nghiên cứu 7
1.5. Cấu trúc bài luận 8
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT 9
2.1. Giá trị vòng đời khách hàng (Customer Lifetime Value) 9
2.2. Mô hình RFM 9
2.3. Xích Markov 10
2.3.1. Tính chất Markov 10
2.3.2. Ma trận chuyển trạng thái 10
2.3.3. Phân phối trạng thái sau nhiều bước 11
2.3.4. Phân phối dừng 11
2.4. Ước lượng CLV bằng xích Markov 12
2.5. Thuật toán K-means để xác định trạng thái 12
2.6. Tổng quan các nghiên cứu liên quan 13
CHƯƠNG 3: DỮ LIỆU VÀ MÔ HÌNH 15
3.1. Nguồn dữ liệu 15
3.2. Tiền xử lý dữ liệu 15
3.3. Chia dữ liệu theo kỳ thời gian 16
3.4. Định nghĩa không gian trạng thái 17
3.5. Xây dựng ma trận chuyển và hàm phần thưởng 18
3.6. Phương án kiểm chứng 19
CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM 20
4.1. Kết quả tiền xử lý dữ liệu 20
4.2. Lựa chọn số cụm và kết quả phân cụm 21
4.3. Ma trận chuyển trạng thái 23
4.4. Kiểm chứng ngoài mẫu 25
4.5. Ước lượng giá trị vòng đời khách hàng 27
4.6. So sánh với mô hình cơ sở và mô phỏng kịch bản 29
4.6.1. So sánh với mô hình cơ sở 29

4.6.2. Mô phỏng kịch bản can thiệp (what-if) 30
4.6.3. Phân phối dừng và xu hướng dài hạn 31
4.7. Thảo luận và gợi ý ra quyết định 31
CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 33
5.1. Kết luận 33
5.2. Hạn chế của nghiên cứu 34
5.3. Hướng phát triển 35
DANH MỤC TÀI LIỆU THAM KHẢO 36

DANH MỤC HÌNH VẼ

Hình 4.1: Phân phối các chỉ số RFM trước và sau chuẩn hóa logarit

Hình 4.2: Phương pháp Elbow và chỉ số Silhouette để lựa chọn số cụm K

Hình 4.3: Biểu đồ phân tán các cụm khách hàng theo Recency - Monetary - Frequency

Hình 4.4: Phân bố khách hàng theo trạng thái qua các kỳ

Hình 4.5: Bản đồ nhiệt ma trận chuyển trạng thái P

Hình 4.6: So sánh phân bố trạng thái dự báo và thực tế ở kỳ kiểm thử

Hình 4.7: Giá trị vòng đời khách hàng (CLV) dự báo theo từng trạng thái

Hình 4.8: So sánh CLV theo mô hình Markov và mô hình cơ sở (baseline)

DANH MỤC BẢNG BIỂU

Bảng 3.1: Tổng quan dữ liệu theo từng kỳ thời gian

Bảng 4.1: Đặc điểm thống kê của các cụm khách hàng

Bảng 4.2: Ma trận chuyển trạng thái P

Bảng 4.3: Kết quả kiểm chứng out-of-sample

Bảng 4.3b: Kiểm chứng có điều kiện trên nhóm khách còn hoạt động

Bảng 4.3c: Ma trận nhầm lẫn ở cấp độ khách hàng

Bảng 4.4: Giá trị vòng đời khách hàng theo từng trạng thái

Bảng 4.5: So sánh CLV Markov với mô hình cơ sở

Bảng 4.6: Kết quả mô phỏng kịch bản can thiệp (what-if)

Bảng 4.7: Phân phối hiện tại và phân phối dừng của tệp khách hàng

CHƯƠNG 1: GIỚI THIỆU

1.1. Bối cảnh và động lực nghiên cứu

Sự phát triển bùng nổ của thương mại điện tử trong thời gian qua đã làm thay đổi cách các doanh nghiệp bán lẻ tiếp cận và quản trị khách hàng. Với các nền tảng như Shopify, WooCommerce, Wix hay các sàn thương mại điện tử như Amazon, Shopee, Lazada, một cửa hàng trực tuyến quy mô không quá lớn có thể ghi nhận rất nhiều giao dịch mỗi năm. Khối lượng dữ liệu giao dịch khổng lồ này có thể mở cơ hội phân tích hành vi khách hàng ở mức độ mà trước đây chỉ có các tập đoàn lớn mới có thể thực hiện.

Trong bối cảnh chi phí thu hút khách hàng mới ngày càng tăng, cạnh tranh ngày càng cao, chiến lược của các doanh nghiệp thương mại điện tử đã dần chuyển dịch từ việc tối đa hóa doanh thu tức thời sang tối đa hóa giá trị dài hạn của khách hàng. Chỉ số phản ánh điều này là Giá trị vòng đời khách hàng (Customer Lifetime Value - CLV), được hiểu là tổng giá trị mà khách hàng dự kiến mang lại cho doanh nghiệp trong suốt thời gian sử dụng hàng hóa hoặc dịch vụ.

Việc ước lượng chính xác CLV có ý nghĩa thực tiễn trực tiếp, cho phép doanh nghiệp phân bổ ngân sách marketing một cách hợp lý, xác định nhóm khách hàng đáng đầu tư giữ chân, thiết kế các chương trình khách hàng thân thiết và định lượng được hiệu quả của các chiến dịch chăm sóc khách hàng. Đối với một cửa hàng trên nền tảng Shopify, một trong những câu hỏi làm đau đầu nhất là "nên chi bao nhiêu tiền để giữ chân một khách hàng thuộc nhóm nào", câu trả lời cho câu hỏi phụ thuộc trực tiếp vào ước lượng CLV.

1.2. Vấn đề nghiên cứu

Phương pháp phổ biến nhất để phân khúc khách hàng trong bán lẻ là mô hình RFM, dựa trên ba chỉ số: Recency (khoảng thời gian từ lần mua gần nhất), Frequency (tần suất mua hàng) và Monetary (tổng giá trị chi tiêu). Ưu điểm của RFM là đơn giản, dễ diễn giải và chỉ cần dữ liệu giao dịch cơ bản. Tuy nhiên, mô hình RFM truyền thống bộc lộ ba hạn chế quan trọng.

- Thứ nhất, RFM chỉ cung cấp một dữ liệu tại một thời điểm cố định khi quan sát. Nó cho biết khách hàng đang thuộc nhóm nào, nhưng không mô tả được quá trình khách hàng dịch chuyển giữa các nhóm theo thời gian.

- Thứ hai, RFM không đưa ra kết quả là một con số, một giá trị tiền tệ có thể dùng trực tiếp mà là các nhãn phân loại phân khúc.
- Thứ ba, RFM không mô hình hóa được rủi ro rời bỏ trong khi đây là một yếu tố then chốt quyết định giá trị dài hạn của khách hàng.

Những hạn chế này đòi hỏi một phương pháp có khả năng mô hình hóa sự thay đổi và tính ngẫu nhiên trong hành vi khách hàng. Xích Markov là công cụ phù hợp, bằng cách coi mỗi phân khúc RFM là một trạng thái và ước lượng xác suất chuyển dịch giữa các trạng thái qua các kỳ, ta có thể dự báo cơ cấu tệp khách hàng trong tương lai và từ đó dự đoán CLV.

Hướng tiếp cận này đã được đặt nền móng bởi Pfeifer và Carraway (2000), những người đầu tiên đề xuất mô hình hóa quan hệ khách hàng bằng xích Markov với các trạng thái xây dựng từ RFM. Gần đây nhất, Harish và Malathy (2023) đã triển khai cụ thể hướng này trên dữ liệu giao dịch bán lẻ, sử dụng thuật toán K-means để xác định trạng thái và ma trận chuyển Markov để dự báo dịch chuyển phân khúc. Nghiên cứu này kế thừa trực tiếp khung phương pháp của Harish và Malathy (2023), đồng thời bổ sung một số cải tiến sẽ được nêu ở mục 1.3.

1.3. Mục tiêu và câu hỏi nghiên cứu

Mục tiêu tổng quát của nghiên cứu là xây dựng và kiểm chứng một khung phân tích cho phép phân khúc khách hàng thương mại điện tử theo trạng thái RFM và dự báo giá trị vòng đời của họ bằng mô hình xích Markov. Cụ thể, nghiên cứu hướng tới trả lời bốn câu hỏi sau:

1. Có thể phân chia tệp khách hàng của một cửa hàng trực tuyến thành bao nhiêu trạng thái hành vi khác biệt dựa trên chỉ số RFM?
2. Xác suất dịch chuyển giữa các trạng thái này qua các kỳ thời gian là bao nhiêu, và ma trận chuyển trạng thái cho biết điều gì về rủi ro rời bỏ của từng nhóm?
3. Mô hình xích Markov dự báo cơ cấu tệp khách hàng ở kỳ tiếp theo chính xác đến mức nào khi áp dụng với những dữ liệu bên ngoài dữ liệu huấn luyện?
4. Giá trị vòng đời khách hàng ước lượng theo mô hình Markov khác biệt ra sao so với phương pháp cơ sở và kết quả này gợi ý điều gì cho việc phân bổ ngân sách giữ chân khách hàng?

So với nghiên cứu gốc của Harish và Malathy (2023), báo cáo này bổ sung bốn điểm mở rộng:

- Huấn luyện thuật toán K-means một lần trên toàn bộ dữ liệu gộp của mọi kỳ thay vì huấn luyện riêng từng kỳ, nhằm đảm bảo nhãn trạng thái đồng nhất tuyệt đối giữa các kỳ
- Tính CLV bằng công thức chiết khấu của Pfeifer và Carraway (2000) thay vì chỉ dừng ở dự báo phân bố cụm
- Bổ sung một mô hình cơ sở để đối chiếu định lượng
- Thực hiện mô phỏng kịch bản can thiệp (what-if) nhằm gắn kết quả mô hình với quyết định marketing cụ thể.

1.4. Đối tượng và phạm vi nghiên cứu

1.4.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu là dữ liệu hành vi mua hàng của các khách hàng một cửa hàng bán lẻ trực tuyến. Đối tượng phương pháp là xích Markov thời gian rời rạc với không gian trạng thái hữu hạn được xây dựng từ chỉ số RFM, kết hợp với thuật toán phân cụm K-means.

1.4.2. Phạm vi nghiên cứu

Về dữ liệu, nghiên cứu sử dụng bộ dữ liệu công khai Online Retail II của kho lưu trữ UCI Machine Learning Repository, ghi nhận toàn bộ giao dịch của một cửa hàng bán lẻ trực tuyến đăng ký tại Vương quốc Anh trong giai đoạn từ ngày 01/12/2009 đến ngày 09/12/2011.

Về phương pháp, nghiên cứu giới hạn ở xích Markov thuần nhất bậc một tức là giả định xác suất chuyển trạng thái không thay đổi theo thời gian và trạng thái tương lai chỉ phụ thuộc trạng thái hiện tại. Nghiên cứu không mở rộng sang mô hình Markov ẩn hay Markov bậc cao, mặc dù có thảo luận các hướng này ở Chương 5.

Về nội dung, nghiên cứu tập trung vào thành phần giá trị kỳ vọng tương lai của CLV, không tính phần giá trị lũy kế trong quá khứ. Các yếu tố chi không được đưa vào do bộ dữ liệu không cung cấp, do đó mục tiêu để mô hình tối ưu là doanh thu chứ không phải lợi nhuận biên.

1.5. Cấu trúc bài luận

Báo cáo được trình bày theo 5 chương.

- Chương 1: Giới thiệu bối cảnh, vấn đề, mục tiêu và phạm vi nghiên cứu.
- Chương 2: Trình bày cơ sở lý thuyết về CLV, RFM, xích Markov, công thức CLV theo Markov, thuật toán K-means và tổng quan các nghiên cứu liên quan.
- Chương 3: Mô tả bộ dữ liệu, tiền xử lý, định nghĩa trạng thái, xây dựng ma trận chuyển và kiểm chứng.
- Chương 4: Trình bày và thảo luận toàn bộ kết quả thực nghiệm.
- Chương 5: Kết luận, nêu hạn chế và đề xuất hướng phát triển.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Giá trị vòng đời khách hàng (Customer Lifetime Value)

Giá trị vòng đời khách hàng là giá trị hiện tại của dòng tiền kỳ vọng (lợi ích kinh tế) mà một khách hàng mang lại trong suốt mối quan hệ kinh tế (thời gian sử dụng hoặc sẽ sử dụng sản phẩm/dịch vụ). Khái niệm này đánh dấu bước chuyển từ tư duy giao dịch đơn lẻ sang tư duy quản trị quan hệ khách hàng dài hạn.

Công thức CLV cổ điển dựa trên nguyên lý dòng tiền chiết khấu có dạng:

$$CLV = \sum_{t=0}^{T} \frac{[\, R_t \times P_t \,]}{(1 + d)^t}$$

trong đó R_t là dòng tiền kỳ vọng thu được từ khách hàng ở kỳ t, P_t là xác suất khách hàng còn duy trì quan hệ tại kỳ t và d là tỷ lệ chiết khấu, phản ánh giá trị thời gian của tiền tệ.

Về mặt cấu thành, CLV được chia thành hai phần: giá trị lũy kế trong quá khứ (historical value) và giá trị kỳ vọng trong tương lai (future potential value). Nghiên cứu này tập trung vào thành phần thứ hai, vì đây mới là cơ sở cho các quyết định phân bổ nguồn lực hướng tới tương lai.

Thách thức lớn nhất khi áp dụng công thức trên là việc ước lượng đồng thời hai đại lượng R_t và P_t vì cả hai đều biến động theo hành vi khách hàng. Mô hình xích Markov giải quyết vấn đề này bằng cách gán cả hai đại lượng cho từng trạng thái hành vi, như trình bày ở mục 2.4.

2.2. Mô hình RFM

Mô hình RFM tóm tắt hành vi mua hàng của một khách hàng qua ba chỉ số:

- Recency (R): số ngày kể từ lần giao dịch gần nhất tính đến thời điểm quan sát. Giá trị R càng nhỏ thể hiện khách hàng càng tương tác gần đây, do đó càng có khả năng quay lại.
- Frequency (F): số lần giao dịch phân biệt trong kỳ quan sát. F phản ánh mức độ sử dụng, gắn bó và thói quen mua hàng.
- Monetary (M): tổng giá trị chi tiêu trong kỳ quan sát, phản ánh quy mô đóng góp lợi ích kinh tế.

Cơ sở lý luận của RFM là giả thuyết thực nghiệm: khách hàng mua gần đây, mua thường xuyên và chi tiêu nhiều có xác suất quay lại cao hơn và mang lại giá trị lớn hơn. Chen, Sain và Guo (2012) đã chứng minh tính hiệu quả của RFM trong phân khúc khách hàng bán lẻ trực tuyến, đồng thời chính là nghiên cứu giới thiệu bộ dữ liệu Online Retail được sử dụng rộng rãi sau này.

Tuy nhiên, như đã nêu ở mục 1.2, RFM là mô hình mô tả tĩnh. Harish và Malathy (2023) chỉ rõ rằng để khắc phục hạn chế này, cách tiếp cận hợp lý là kết hợp RFM với một mô hình ngẫu nhiên hay cụ thể nghiên cứu này sử dụng xích Markov.

2.3. Xích Markov

2.3.1. Tính chất Markov

Cho X_t với $t = 0, 1, 2, \ldots$ là một quá trình ngẫu nhiên nhận giá trị trong không gian trạng thái hữu hạn $S = \{s_0, s_1, \ldots, s_n\}$. Quá trình này được gọi là một xích Markov nếu nó thỏa mãn tính chất Markov, hay tính chất "không nhớ":

$$P(X_{t+1} = j \mid X_t = i, X_{t-1} = i_{t-1}, \ldots, X_0 = i_0) = P(X_{t+1} = j \mid X_t = i)$$

Nói cách khác, phân phối xác suất của trạng thái tương lai chỉ phụ thuộc vào trạng thái hiện tại, độc lập với toàn bộ lịch sử trước đó. Đây là giả định trung tâm của mô hình và cũng là hạn chế lý thuyết cần được thảo luận (xem thêm tại 5.2).

2.3.2. Ma trận chuyển trạng thái

Xác suất chuyển từ trạng thái i sang trạng thái j trong một bước được ký hiệu là:

$$p_{ij} = P(X_{t+1} = j \mid X_t = i)$$

Tập hợp các xác suất này tạo thành ma trận chuyển trạng thái P kích thước $(n+1) \times (n+1)$:

$$P = \begin{bmatrix} p_{00} & p_{01} & \cdots & p_{0n} \\ p_{10} & p_{11} & \cdots & p_{1n} \\ \vdots & \vdots & \ddots & \vdots \\ p_{n0} & p_{n1} & \cdots & p_{nn} \end{bmatrix}$$

Ma trận P là một ma trận ngẫu nhiên (stochastic matrix), thỏa mãn hai điều kiện: $p_{ij} \geq 0$ với mọi i, j và tổng mỗi hàng bằng 1, tức $\Sigma_j p_{ij} = 1$ với mọi i. Điều kiện thứ hai phản ánh thực tế rằng từ một trạng thái bất kỳ, khách hàng chắc chắn sẽ ở một trạng thái nào đó trong kỳ tiếp theo.

Trong thực nghiệm, các phần tử p_{ij} được ước lượng bằng phương pháp hợp lý cực đại, tương đương với tần suất quan sát được:

$$\hat{p}_{ij} = \frac{n_{i \to j}}{n_i}$$

trong đó $n_{i \to j}$ là số lần quan sát thấy sự chuyển từ trạng thái *i* sang *j* trên toàn bộ các cặp kỳ liên tiếp, và n_i là tổng số lần quan sát thấy trạng thái *i*.

2.3.3. Phân phối trạng thái sau nhiều bước

Gọi π_t là vector hàng biểu diễn phân phối khách hàng trên các trạng thái tại kỳ *t*. Khi đó phân phối ở kỳ tiếp theo được xác định bởi:

$$\pi_{t+1} = \pi_t \cdot P$$

và tổng quát hơn, sau k bước:

$$\pi_{t+k} = \pi_t \cdot P^k$$

Công thức này chính là cơ chế dự báo của mô hình, khi biết cơ cấu tệp khách hàng hiện tại và ma trận chuyển thì ta có thể dự báo được cơ cấu ở bất kỳ kỳ nào trong tương lai.

2.3.4. Phân phối dừng

Với một xích Markov hữu hạn, bất khả quy và không tuần hoàn, tồn tại duy nhất một phân phối dừng π^* thỏa mãn:

$$\pi^* \cdot P = \pi^* \qquad \text{và} \qquad \sum_j \pi_j^* = 1$$

Phân phối dừng có ý nghĩa thực tiễn quan trọng vì nó cho biết cơ cấu tệp khách hàng sẽ hội tụ về đâu trong dài hạn nếu doanh nghiệp không có bất kỳ can thiệp marketing nào. So sánh phân phối hiện tại với phân phối dừng giúp nhận diện xu hướng suy giảm hoặc tăng trưởng tự nhiên của tệp khách hàng.

Cũng cần lưu ý mặt trái của tính hội tụ này khi Harish và Malathy (2023) đã cảnh báo rằng việc dự báo quá nhiều bước có thể làm kết quả tiến dần về phân phối dừng và mất đi khả năng phân biệt. Do đó mô hình Markov phù hợp nhất cho dự báo trong một số ít kỳ liên tiếp.

2.4. Ước lượng CLV bằng xích Markov

Kết nối giữa mục 2.1 và mục 2.3 được thực hiện thông qua vector phần thưởng. Gọi R là vector cột kích thước (n+1), trong đó R_i là doanh thu trung bình mà một khách hàng ở trạng thái i tạo ra trong một kỳ. Theo Pfeifer và Carraway (2000), giá trị vòng đời khách hàng trong T kỳ được tính bằng:

$$CLV = \sum_{t=0}^{T} \frac{P^t \cdot R}{(1 + d)^t}$$

Kết quả là một vector, trong đó phần tử thứ i chính là CLV kỳ vọng của một khách hàng hiện đang ở trạng thái i. Khi cho T tiến ra vô cùng và đặt $\gamma = 1/(1+d)$ là hệ số chiết khấu, chuỗi trên hội tụ và có dạng đóng:

$$V = (I - \gamma P)^{-1} \cdot R$$

với I là ma trận đơn vị. Dạng đóng này chỉ tồn tại khi $\gamma < 1$, điều luôn thỏa mãn với tỷ lệ chiết khấu dương.

Công thức trên cũng có thể được viết dưới dạng hệ phương trình đệ quy Bellman, thể hiện rõ bản chất "quá trình Markov có phần thưởng" (Markov Reward Process):

$$V(s_i) = R(s_i) + \gamma \cdot \sum_j p_{ij} \cdot V(s_j)$$

Nói một cách đơn giản, giá trị của một khách hàng ở trạng thái i bằng phần thưởng nhận được ngay tại trạng thái đó, cộng với giá trị chiết khấu kỳ vọng của các trạng thái mà khách hàng có thể chuyển đến. Điểm mạnh của cách tiếp cận này là rủi ro rời bỏ được nội sinh hóa, nếu trạng thái i có xác suất cao chuyển sang trạng thái "rời bỏ" (với phần thưởng bằng 0), thì $V(s_i)$ sẽ tự động giảm mà không cần ước lượng riêng P_t.

2.5. Thuật toán K-means để xác định trạng thái

Mô hình Markov đòi hỏi một tập trạng thái rời rạc và hữu hạn. Có hai cách phổ biến để tạo trạng thái từ RFM, đó là chia theo phân vị thủ công (ví dụ chia mỗi chỉ số thành 5 nhóm), hoặc dùng thuật toán phân cụm. Harish và Malathy (2023) lập luận rằng cách thứ hai ưu việt hơn, do cách chia phân vị dễ gây lệch khi phân phối dữ liệu không đều, ví dụ nếu phần lớn khách hàng đều mới mua gần đây, điểm Recency sẽ dồn hết vào nhóm cao nhất.

Thuật toán K-means phân chia n quan sát thành K cụm sao cho tối thiểu hóa tổng bình phương khoảng cách trong cụm (Within-Cluster Sum of Squares - WCSS):

$$J = \sum_{j=1}^{K} \sum_{x \in C_j} \|x - \mu_j\|^2$$

trong đó C_j là tập các điểm thuộc cụm thứ j, x là vector đặc trưng RFM của một khách hàng, và μ_j là tâm cụm (centroid) của cụm C_j. Thuật toán thực hiện lặp hai bước: gán mỗi điểm vào cụm có tâm gần nhất theo khoảng cách Euclid, sau đó cập nhật tâm cụm bằng trung bình các điểm trong cụm cho đến khi hội tụ.

Để chọn số cụm K, nghiên cứu sử dụng đồng thời hai tiêu chí. Phương pháp Elbow quan sát tốc độ giảm của WCSS theo K và chọn điểm mà việc tăng thêm cụm không còn mang lại cải thiện đáng kể (Marutho và cộng sự, 2018). Chỉ số Silhouette đo mức độ một điểm gần với cụm của nó so với cụm gần nhất khác, nhận giá trị trong khoảng $[-1, 1]$, giá trị càng cao càng tốt.

Cần nhấn mạnh rằng trong nghiên cứu này, K-means không đóng vai trò một công cụ phân nhóm độc lập, mà là bước định nghĩa không gian trạng thái S cho mô hình Markov ở bước sau.

2.6. Tổng quan các nghiên cứu liên quan

Ý tưởng mô hình hóa quan hệ khách hàng bằng xích Markov được Pfeifer và Carraway (2000) đặt nền móng trong nghiên cứu công bố trên Journal of Interactive Marketing. Các tác giả đề xuất sử dụng biến RFM sau khi rời rạc hóa làm trạng thái của xích Markov, và đưa ra công thức tính CLV mà nghiên cứu này kế thừa ở mục 2.4.

Cheng và cộng sự (2012) áp dụng mô hình Markov kết hợp khai phá dữ liệu để dự báo CLV cho một doanh nghiệp sửa chữa ô tô tại Đài Loan, chứng minh tính khả thi của phương pháp trên dữ liệu doanh nghiệp thực tế. Ở nhánh phân khúc dựa trên RFM, Aggelis và Christodoulakis (2005) cùng Cheng và Chen (2009) cho thấy việc kết hợp RFM với các kỹ thuật phân nhóm (phân cụm và lý thuyết tập thô) cho kết quả phân khúc khách quan hơn so với chia ngưỡng thủ công. Ở nhánh định giá khách hàng bằng mô hình ngẫu nhiên, Hwang (2016) cùng Mzoughia và Limam (2015) tiếp tục cải tiến khung ước lượng CLV dựa trên xích Markov, củng cố thêm cơ sở phương pháp luận mà nghiên cứu này kế thừa.

Nghiên cứu gần nhất và cũng là nghiên cứu nền tảng trực tiếp của báo cáo này là Harish và Malathy (2023), công bố trên tạp chí Intelligent Automation & Soft Computing. Các tác giả sử dụng dữ liệu giao dịch bán lẻ gồm 375.617 bản ghi trong 12 tháng, tính chỉ số RFM, chuẩn hóa logarit, áp dụng K-means với K = 6 (chọn bằng phương pháp Elbow) và bổ sung một cụm 0 đại diện cho khách hàng không phát sinh giao dịch trong kỳ, tạo thành không gian bảy trạng thái. Dữ liệu được chia thành sáu kỳ hai tháng, năm kỳ đầu dùng để ước lượng ma trận chuyển 7 × 7, kỳ cuối được giữ lại làm tập kiểm thử (lưu ý kỳ cuối có số lượng dữ liệu ít hơn rất nhiều so với các kỳ còn lại). Kết quả cho thấy sai lệch trung bình giữa phân bố dự báo và thực tế khoảng 15%, được các tác giả đánh giá là chấp nhận được với quy mô mẫu nghiên cứu. Ma trận chuyển thu được cũng cho thấy quy luật đáng chú ý khi chỉ ra rằng xác suất rời bỏ giảm dần khi đi lên các phân khúc giá trị cao hơn, từ khoảng 67% ở cụm thấp nhất xuống còn khoảng 4% ở cụm khách hàng giá trị cao.

Ở hướng nâng cao hơn, Netzer, Lattin và Srinivasan (2008) sử dụng mô hình Markov ẩn (Hidden Markov Model) để mô hình hóa động lực quan hệ khách hàng, trong đó trạng thái quan hệ không quan sát trực tiếp được mà phải suy diễn từ hành vi. Hướng này được đề xuất như một khả năng phát triển tiếp theo ở Chương 5.

Nghiên cứu hiện tại kế thừa gần như nguyên vẹn khung phương pháp RFM, K-means và xích Markov của Harish và Malathy (2023), nhưng bổ sung bốn điểm mở rộng đã nêu ở mục 1.3. Trong đó, cải tiến về cách huấn luyện K-means là đáng chú ý nhất về mặt phương pháp luận.

CHƯƠNG 3: DỮ LIỆU VÀ MÔ HÌNH

3.1. Nguồn dữ liệu

Nghiên cứu sử dụng bộ dữ liệu Online Retail II, được cung cấp công khai bởi UCI Machine Learning Repository và phổ biến trên nền tảng Kaggle. Bộ dữ liệu ghi nhận toàn bộ giao dịch của một cửa hàng bán lẻ trực tuyến đăng ký tại Vương quốc Anh, chuyên kinh doanh quà tặng cho mọi dịp, trong giai đoạn từ 01/12/2009 đến 09/12/2011.

Việc lựa chọn bộ dữ liệu này dựa trên ba lý do:

- Bộ dữ liệu công khai, tải về và sử dụng tự do, đảm bảo tính tái lập
- Là bộ dữ liệu được Harish và Malathy (2023) sử dụng, cho phép đối chiếu kết quả với nghiên cứu trước đó
- Độ dài hai năm đủ để chia thành nhiều kỳ quan sát, tạo ra số lượng quan sát chuyển trạng thái đủ lớn cho việc ước lượng ma trận chuyển.

Các trường dữ liệu chính bao gồm:

- Invoice: mã hóa đơn. Mã bắt đầu bằng ký tự "C" biểu thị giao dịch bị hủy.
- StockCode và Description: mã và mô tả sản phẩm.
- Quantity: số lượng sản phẩm trong giao dịch.
- InvoiceDate: ngày giờ phát sinh giao dịch.
- Price: đơn giá sản phẩm.
- Customer ID: mã định danh khách hàng.
- Country: quốc gia của khách hàng.

3.2. Tiền xử lý dữ liệu

Quy trình làm sạch dữ liệu được thực hiện theo trình tự sau, kế thừa cách xử lý của Harish và Malathy (2023):

1. Loại bỏ các bản ghi thiếu mã khách hàng.
2. Loại bỏ các hóa đơn hủy, giao dịch không thành công (mã bắt đầu bằng "C").
3. Loại bỏ các bản ghi trả hàng hoặc nhập liệu lỗi có Quantity ≤ 0 hoặc Price ≤ 0.
4. Tạo biến doanh thu Amount = Quantity $\times$ Price cho mỗi dòng giao dịch.

5. Loại bỏ các giá trị ngoại lai cực trị vượt phân vị 99,5% của biến Amount, nhằm tránh một số ít giao dịch bán buôn khổng lồ chi phối kết quả phân cụm.

Kết quả sau tiền xử lý được trình bày ở Chương 4.

3.3. Chia dữ liệu theo kỳ thời gian

Để quan sát được sự dịch chuyển trạng thái, dữ liệu phải được chia thành các kỳ thời gian liên tiếp có độ dài bằng nhau. Nghiên cứu gốc chia 12 tháng dữ liệu thành sáu kỳ hai tháng. Do bộ dữ liệu trải dài 739 ngày (01/12/2009 - 09/12/2011), nếu bắt đầu từ ngày đầu của dữ liệu thì phần dư cuối chuỗi chỉ còn 9 ngày (01/12/2011 - 09/12/2011), quá ngắn để làm kỳ kiểm thử (trong cửa sổ 9 ngày, Recency tối đa chỉ bằng 9 trong khi các kỳ khác khoảng 61, Frequency gần như luôn bằng 1 và Monetary chỉ tích lũy được 9 ngày doanh thu), ảnh hưởng nghiêm trọng tới việc phân cụm, làm mọi chỉ số kiểm chứng mất ý nghĩa.

Vì vậy nghiên cứu này sử dụng ngày 01/11/2011 làm mốc rồi lùi hai tháng mỗi bước, thu được 11 kỳ huấn luyện (mỗi kỳ 59-62 ngày) và 1 kỳ kiểm thử kéo dài 39 ngày (01/11/2011 - 09/12/2011). Phần dữ liệu tháng 12/2009 (chiếm 4,0% doanh thu) nằm ngoài khoảng và được loại bỏ với mục tiêu giữ mọi kỳ huấn luyện có độ dài gần như đồng nhất, đảm bảo kỳ kiểm thử đủ dài để đối chiếu có ý nghĩa. Việc chọn độ dài kỳ hai tháng vẫn là một đánh đổi có cân nhắc để kỳ không quá ngắn khiến phần lớn khách hàng rơi vào trạng thái không mua hàng và kỳ không quá dài làm giảm số lần quan sát chuyển trạng thái và che lấp các dịch chuyển ngắn hạn. Kết quả là 10 cặp kỳ liên tiếp được dùng để ước lượng ma trận chuyển.

PeriodIdx	TuNgay	DenNgay	SoNgayKy	VaiTro	SoKhach	SoHoaDon	DoanhThu
0	2010-01-01	2010-02-28	59	train	1,225	2,067	852,797
1	2010-03-01	2010-04-30	61	train	1,608	2,808	1,121,199
2	2010-05-01	2010-06-30	61	train	1,626	2,825	1,070,720
3	2010-07-01	2010-08-31	62	train	1,479	2,611	985,297
4	2010-09-01	2010-10-31	61	train	2,159	3,733	1,545,647
5	2010-11-01	2010-12-31	61	train	1,953	3,913	1,736,215
6	2011-01-01	2011-02-28	59	train	1,224	1,954	800,309
7	2011-03-01	2011-04-30	61	train	1,515	2,424	913,091
8	2011-05-01	2011-06-30	61	train	1,624	2,885	1,089,280
9	2011-07-01	2011-08-31	62	train	1,482	2,564	1,028,725
10	2011-09-01	2011-10-31	61	train	2,129	3,618	1,618,828
11	2011-11-01	2011-12-09	39	TEST	1,896	3,386	1,304,243

Bảng 3.1: Tổng quan dữ liệu theo từng kỳ thời gian

3.4. Định nghĩa không gian trạng thái

Chỉ số RFM được tính riêng cho từng khách hàng trong từng kỳ. Recency được tính bằng số ngày từ giao dịch cuối cùng của khách hàng đến ngày kết thúc kỳ, Frequency là số hóa đơn phân biệt trong kỳ, Monetary là tổng giá trị Amount trong kỳ. Việc tính riêng theo từng kỳ là bắt buộc để thang đo Recency và Frequency giữa các kỳ có thể so sánh được, không bị thiên lệch bởi độ mới của dữ liệu.

Do kỳ kiểm thử chỉ dài 39 ngày trong khi các kỳ huấn luyện dài 59-62 ngày, hai chỉ số tích lũy theo thời gian là Frequency và Monetary được quy về cường độ trên một độ dài chuẩn 61 ngày theo công thức:

$$F_{adj} = F \times \frac{61}{n_{ngày}} \qquad M_{adj} = M \times \frac{61}{n_{ngày}}$$

Cách quy đổi này tránh việc khách ở kỳ ngắn trông thưa hơn và nghèo hơn chỉ vì cửa sổ quan sát ngắn hơn. Riêng Recency không được quy đổi vì nó là khoảng cách thời gian chứ không phải đại lượng tích lũy, ví dụ mua cách đây 20 ngày mang cùng một ý nghĩa ở mọi độ dài cửa sổ. Hệ số quy đổi của các kỳ huấn luyện nằm trong khoảng 0,984-1,034, riêng kỳ kiểm thử là 1,564.

Do ba chỉ số có phân phối lệch phải mạnh và đơn vị đo khác nhau, dữ liệu được biến đổi logarit theo công thức log(1 + x) rồi chuẩn hóa bằng StandardScaler về phân phối có trung bình 0 và độ lệch chuẩn 1. Bước chuẩn hóa đảm bảo cả ba chỉ số đóng góp trọng số ngang nhau khi tính khoảng cách Euclid trong thuật toán K-means.

Điểm khác biệt so với nghiên cứu gốc là nghiên cứu này huấn luyện K-means một lần duy nhất trên tập dữ liệu gộp của 11 kỳ huấn luyện, sau đó dùng mô hình đã huấn luyện để gán nhãn cho từng quan sát ở mỗi kỳ. Cách làm này đảm bảo rằng cùng một cụm thì ở kỳ nào cũng mang cùng ý nghĩa hành vi, điều kiện tiên quyết để ma trận chuyển có ý nghĩa. Sau khi phân cụm, các nhãn cụm được sắp xếp lại theo thứ tự tăng dần của giá trị Monetary trung bình để nhãn có ý nghĩa diễn giải nhất quán. Để bảo đảm tính out-of-sample, StandardScaler, K-means, việc chọn số cụm K và việc ước lượng vector phần thưởng R đều chỉ dựa trên 18.024 quan sát của 11 kỳ huấn luyện, 1.896 quan sát của kỳ kiểm thử chỉ được gán trạng thái bằng phép dự đoán, không tham gia định nghĩa tâm cụm.

Cuối cùng, bổ sung trạng thái 0 đại diện cho khách hàng không phát sinh giao dịch nào trong kỳ. Trạng thái này mang ý nghĩa kép quan trọng, đó là chuyển từ một trạng thái hoạt động sang trạng thái 0 tương ứng với sự kiện rời bỏ (churn), trong khi chuyển từ trạng thái 0 sang một trạng thái hoạt động tương ứng với việc thu hút hoặc kích hoạt lại khách hàng. Nhờ đó, rủi ro rời bỏ được mô hình hóa nội sinh trong ma trận chuyển thay vì phải ước lượng bằng một mô hình riêng biệt.

Không gian trạng thái cuối cùng là S = {0, 1, 2, …, K}, với K là số cụm được chọn theo tiêu chí Elbow và Silhouette.

3.5. Xây dựng ma trận chuyển và hàm phần thưởng

Với mỗi cặp kỳ liên tiếp (t, t+1), mỗi khách hàng trong toàn bộ tệp đóng góp một quan sát chuyển trạng thái (i, j). Số lần chuyển được cộng dồn trên tất cả các cặp kỳ thuộc tập huấn luyện, sau đó chia cho tổng số quan sát ở trạng thái gốc để thu được ma trận xác suất, theo công thức ước lượng ở mục 2.3.2.

Vector phần thưởng R được xây dựng từ doanh thu trung bình mỗi kỳ trên tập huấn luyện của khách hàng thuộc từng trạng thái. Trạng thái 0 được gán $R_0 = 0$, phản ánh trung thực thực tế kinh tế rằng khách hàng không giao dịch thì không tạo ra doanh thu.

Về tỷ lệ chiết khấu, nghiên cứu sử dụng mức 10% mỗi năm, quy đổi về tỷ lệ chiết khấu theo kỳ bằng công thức $d_{\text{kỳ}} = (1 + d_{\text{năm}})^{1/m} - 1$, trong đó m là số kỳ trong một năm. Đây là mức chiết khấu thông dụng trong các nghiên cứu CLV, phản ánh chi phí vốn của một doanh nghiệp bán lẻ.

3.6. Phương án kiểm chứng

Để đánh giá năng lực dự báo thực sự của mô hình, dữ liệu được chia theo mốc thời gian thay vì chia ngẫu nhiên. Toàn bộ các cặp kỳ liên tiếp trừ cặp cuối cùng được dùng để ước lượng ma trận chuyển P. Kỳ cuối cùng được giữ lại hoàn toàn làm tập kiểm thử (tập test).

Quy trình kiểm chứng: lấy phân bố trạng thái thực tế ở kỳ áp chót, nhân với ma trận P để thu được phân bố dự báo cho kỳ cuối, rồi so sánh với phân bố thực tế quan sát được. Các chỉ tiêu đánh giá gồm sai số tuyệt đối trung bình (MAE) và căn bậc hai của sai số bình phương trung bình (RMSE) trên số đếm khách hàng, sai số trung bình tính bằng điểm phần trăm (MAE_tỷ_lệ) và khoảng cách biến thiên toàn phần (TVD); hai chỉ số dựa trên tỷ trọng trạng thái được định nghĩa bởi:

$$MAE_{tỷ\ lệ} = \frac{100}{n}\sum_i |\hat{p}_i - p_i| \qquad TVD = \frac{1}{2}\sum_i |\hat{p}_i - p_i|$$

trong đó $\hat{p}_i$ và p_i lần lượt là tỷ trọng dự báo và thực tế của trạng thái i, n là số trạng thái; TVD luôn nằm trong [0, 1] và đọc được trực tiếp. Hai chỉ số TVD và MAE_tỷ_lệ được ưu tiên vì cùng độc lập với quy mô mẫu và có thang đo cố định, nhờ đó so sánh được giữa các kỳ có số khách khác nhau: TVD tóm tắt sai lệch của toàn bộ phân bố trạng thái trong một con số, còn MAE_tỷ_lệ phản ánh mức sai trung bình theo tỷ trọng ở từng trạng thái, bổ trợ nhau giữa góc nhìn tổng thể và chi tiết. Chỉ số MAPE không được sử dụng vì mẫu số của nó là số khách của từng trạng thái, khiến chỉ số nổ lên vô nghĩa khi một trạng thái chỉ có vài khách.

Ngoài ra, mô hình Markov được đối chiếu với một mô hình cơ sở đơn giản (baseline) rằng giả định khách hàng duy trì vĩnh viễn mức chi tiêu hiện tại, tức bỏ qua hoàn toàn khả năng dịch chuyển trạng thái và rời bỏ. Việc so sánh này cho phép định lượng giá trị gia tăng mà mô hình ngẫu nhiên mang lại.

Toàn bộ quy trình được triển khai bằng Python với các thư viện pandas, numpy, scikit-learn, matplotlib và seaborn. Mã nguồn đầy đủ được cung cấp kèm theo báo cáo dưới dạng Notebook.

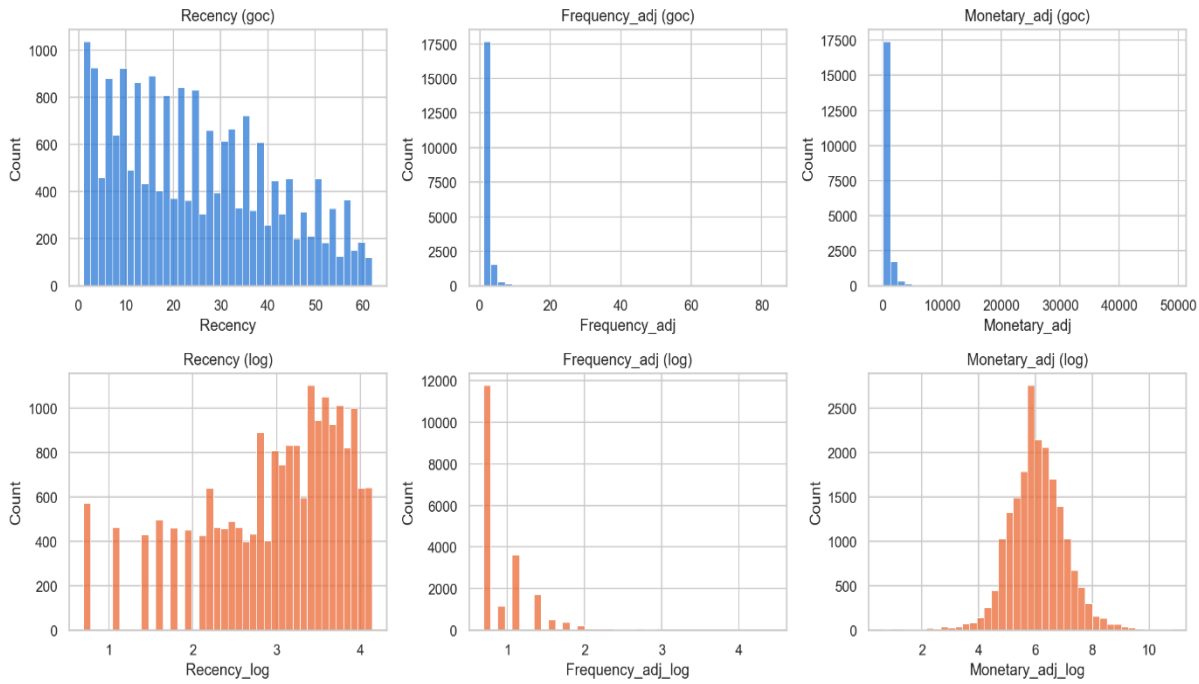
CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM

4.1. Kết quả tiền xử lý dữ liệu

Sau khi áp dụng quy trình làm sạch mô tả ở mục 3.2 và loại phần dữ liệu tháng 12/2009 nằm ngoài lưới kỳ, dữ liệu phân tích tương ứng với 5.753 khách hàng duy nhất, trải dài trên 12 kỳ thời gian hai tháng (11 kỳ huấn luyện và 1 kỳ kiểm thử).

Bảng 3.1 cho thấy quy mô hoạt động của cửa hàng qua các kỳ. Trung bình mỗi kỳ hai tháng có khoảng 1.600 khách hàng với doanh thu quanh mức 1 triệu, riêng các kỳ rơi vào mùa mua sắm cuối năm doanh thu vọt lên khoảng 1,6-1,7 triệu, cao hơn rõ rệt so với mặt bằng. Cần lưu ý kỳ kiểm thử (kỳ 11) chỉ dài 39 ngày nên quy mô của nó không trực tiếp so sánh được với các kỳ huấn luyện hai tháng.

Hình 4.1 minh họa hiệu quả của bước chuẩn hóa logarit. Trước khi biến đổi, cả ba chỉ số RFM đều có phân phối lệch phải rất mạnh, với một số ít khách hàng có giá trị Monetary lớn hơn hàng trăm lần trung vị. Sau khi lấy logarit, phân phối trở nên cân đối hơn đáng kể, tránh được tình trạng một vài quan sát cực trị chi phối vị trí tâm cụm trong thuật toán K-means.

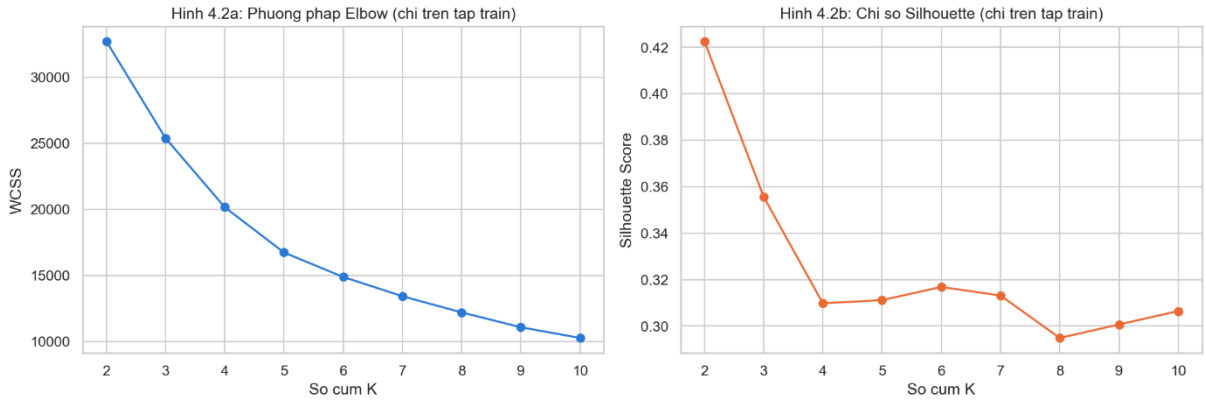


Hình 4.1: Phân phối các chỉ số RFM trước và sau chuẩn hóa logarit

4.2. Lựa chọn số cụm và kết quả phân cụm

Hình 4.2 trình bày kết quả của hai tiêu chí lựa chọn số cụm, đều được tính trên tập huấn luyện. Đường cong WCSS ở biểu đồ bên trái giảm nhanh trong giai đoạn đầu rồi chững lại, điểm gãy khúc rõ nhất xuất hiện tại K = 4, sau đó mức giảm WCSS khi thêm một cụm mới không còn đáng kể so với sự gia tăng độ phức tạp của mô hình. Chỉ số Silhouette ở biểu đồ bên phải đạt cao nhất tại K = 2 rồi giảm và đi ngang trong khoảng 0,30-0,32 từ K = 4 trở đi (đạt 0,309 tại K = 4).

Cần lưu ý rằng, tương tự như quan sát của Harish và Malathy (2023), đường cong Elbow trong dữ liệu bán lẻ thường không có điểm gãy sắc nét, và chỉ số Silhouette đạt cực đại ở K = 2 chủ yếu vì khi đó tệp khách hàng chỉ bị chia thành hai khối lớn thô, mức phân tách này quá ít để phục vụ phân khúc marketing. Do đó, quyết định cuối cùng dựa trên sự kết hợp giữa hai tiêu chí định lượng và yêu cầu về khả năng diễn giải nghiệp vụ rằng số cụm phải đủ ít để mỗi cụm có ý nghĩa marketing rõ ràng, nhưng đủ nhiều để phân biệt được các mức giá trị khách hàng. Nghiên cứu lựa chọn K = 4, tạo thành không gian trạng thái gồm 4 trạng thái.



Hình 4.2: Phương pháp Elbow và chỉ số Silhouette để lựa chọn số cụm K

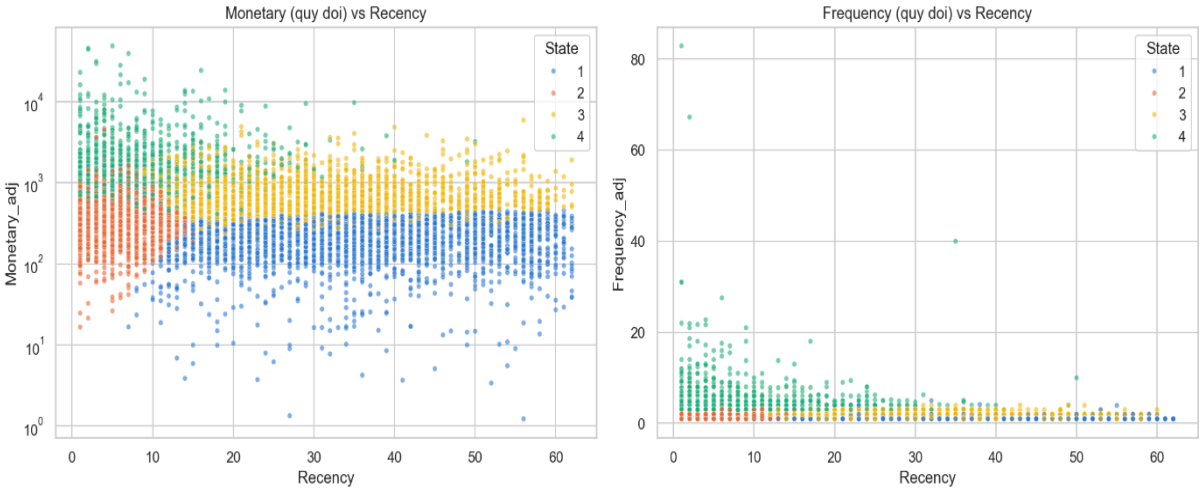
Bảng 4.1 mô tả đặc điểm thống kê của từng cụm sau khi đã sắp xếp lại nhãn theo giá trị Monetary tăng dần.

State	SoQuanSat	Recency_TB	Frequency_TB	Monetary_TB	Monetary_TV
1	7,044	35.85	1.05	220.30	212.72
2	3,305	6.47	1.40	447.48	360.88
3	5,519	29.68	1.56	794.90	636.18
4	2,156	10.03	5.05	2489.75	1455.74

Bảng 4.1: Đặc điểm thống kê của các cụm khách hàng (Frequency và Monetary đã quy đổi về cường độ 61 ngày)

Dựa trên đặc điểm RFM, các trạng thái được đặt tên nghiệp vụ như sau:

- Trạng thái 0 (Vắng mặt / Rời bỏ): khách hàng không phát sinh giao dịch trong kỳ.
- Trạng thái 1 (Giá trị thấp/Đã lâu): Recency cao, Frequency và Monetary thấp, nhóm khách hàng ngủ đông hoặc chỉ mua thử một lần rồi không quay lại.
- Trạng thái 2 (Giá trị thấp/Khách mới): Recency, Frequency và Monetary đều thấp, nhóm khách hàng mới hoặc vừa quay lại, có tiềm năng nhưng chưa hình thành thói quen mua lặp lại.
- Trạng thái 3 (Nguy cơ rời bỏ/Giá trị tốt): Monetary tốt nhưng Recency cao và Frequency trung bình, nhóm giá trị khá nhưng có nguy cơ rời bỏ.
- Trạng thái 4 (Trung thành/Giá trị cao): Recency thấp, Frequency và Monetary cao, nhóm khách hàng trung thành và mang lại nhiều giá trị nhất.

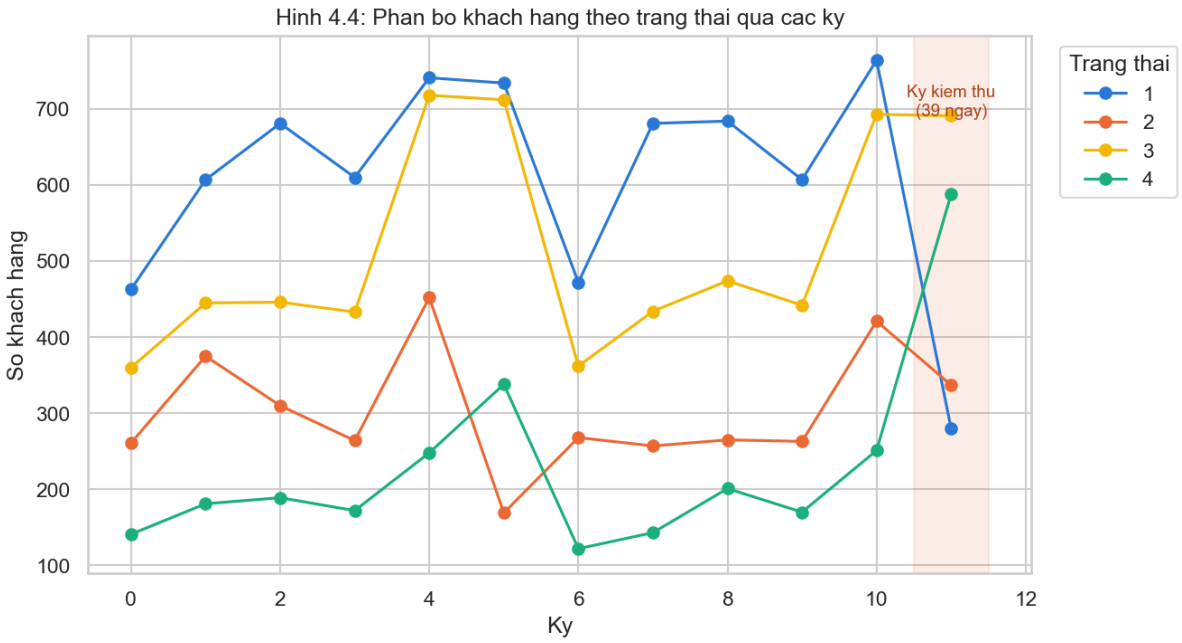


Hình 4.3: Biểu đồ phân tán các cụm khách hàng theo Recency - Monetary - Frequency

Hình 4.3 xác nhận trực quan rằng các cụm được phân tách rõ ràng theo trục giá trị: nhóm khách hàng có Recency thấp đồng thời Frequency và Monetary cao tập trung thành một vùng riêng biệt, tương ứng với phân khúc giá trị cao nhất.

Hình 4.4 theo dõi quy mô của từng trạng thái qua các kỳ. Một quan sát quan trọng là trạng thái 1 chiếm số lượng quan sát nhiều nhất, đồng thời tỉ trọng giữa các trạng thái tương đối ổn định qua các kỳ huấn luyện, riêng kỳ kiểm thử (kỳ 11, chỉ dài 39 ngày và rơi vào mùa mua sắm cuối năm) cơ cấu có biến động rõ rệt so với các kỳ trước. Sự ổn định tương đối của các đường cong ở giai đoạn huấn luyện là điều kiện cần để giả định thuần nhất theo thời gian của ma trận chuyển được chấp nhận, vì nếu quy mô các cụm

biến động mạnh giữa các kỳ thì có yếu tố ngoại sinh chi phối hành vi và ma trận chuyển ước lượng từ dữ liệu gộp sẽ không đáng tin cậy.



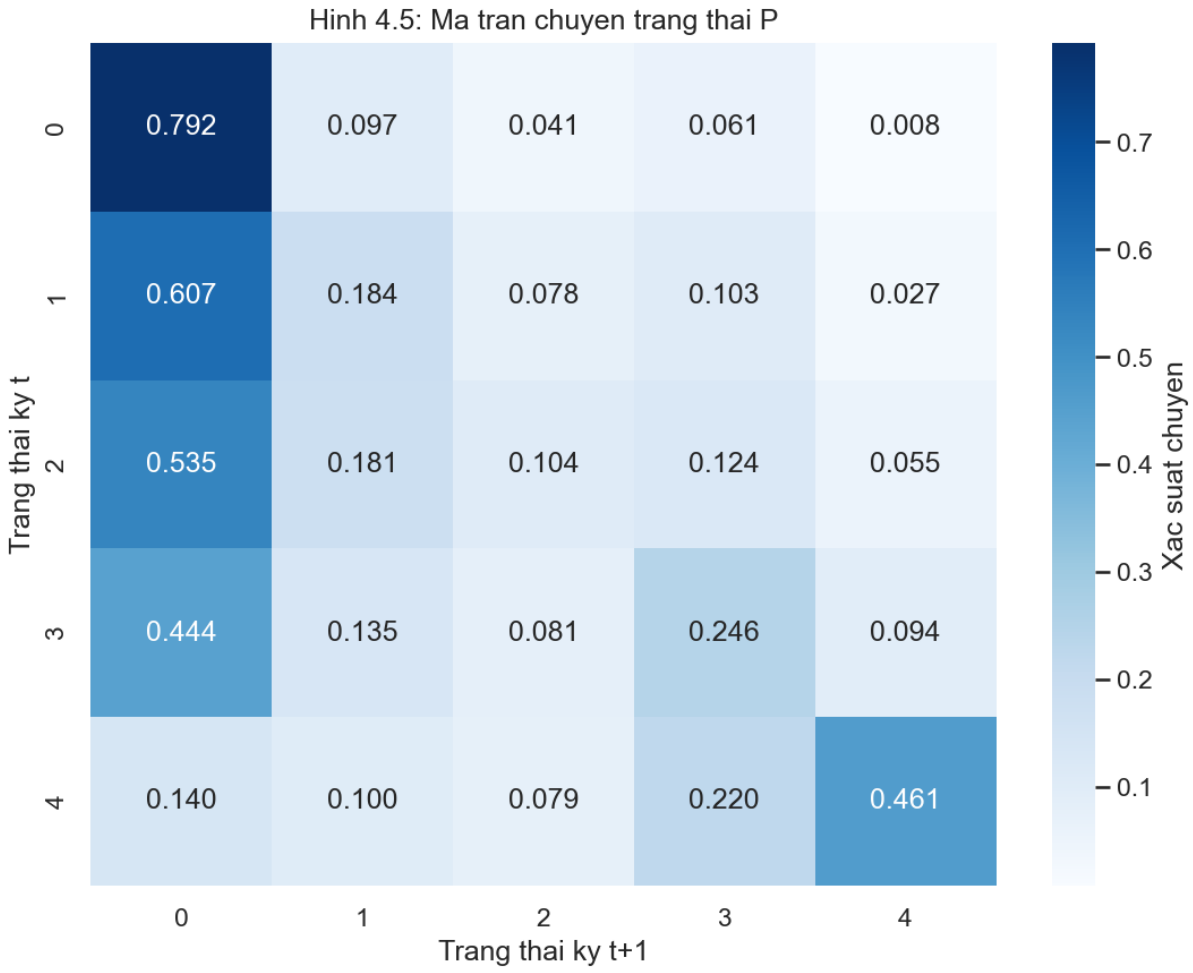
Hình 4.4: Phân bố khách hàng theo trạng thái qua các kỳ

4.3. Ma trận chuyển trạng thái

Ma trận chuyển trạng thái P được ước lượng từ toàn bộ các cặp kỳ liên tiếp trong tập huấn luyện (các kỳ 0 đến 10, tương ứng 10 cặp chuyển tiếp). Kết quả được trình bày ở Bảng 4.2 và trực quan hóa bằng bản đồ nhiệt ở Hình 4.5. Tổng mỗi hàng của ma trận đều bằng 1, xác nhận tính hợp lệ của ma trận ngẫu nhiên.

	0	**1**	**2**	**3**	**4**
0	0.7918	0.0975	0.0411	0.0612	0.0084
1	0.6068	0.1842	0.0783	0.1033	0.0272
2	0.5350	0.1810	0.1044	0.1245	0.0551
3	0.4441	0.1351	0.0806	0.2458	0.0945
4	0.1396	0.1003	0.0787	0.2199	0.4614

Bảng 4.2: Ma trận chuyển trạng thái P



Hình 4.5: Bản đồ nhiệt ma trận chuyển trạng thái P

Ma trận chuyển cho phép rút ra một số nhận định quan trọng về động lực hành vi khách hàng:

- Xác suất rời bỏ giảm dần theo giá trị khách hàng. Xác suất chuyển sang trạng thái 0 từ nhóm giá trị thấp nhất (trạng thái 1) là 60,7%, trong khi từ nhóm giá trị cao nhất (trạng thái 4) chỉ còn 14,0%. Quy luật này hoàn toàn nhất quán với phát hiện của Harish và Malathy (2023), trong đó tỷ lệ tương ứng là khoảng 67% và 4%. Đây là bằng chứng định lượng cho nguyên lý quen thuộc trong marketing rằng khách hàng càng gắn bó thì càng khó rời bỏ.
- Tính "dính" của các trạng thái giá trị cao. Xác suất một khách hàng ở trạng thái cao nhất tiếp tục ở lại trạng thái đó là 46,1%, cao hơn đáng kể so với xác suất tự duy trì của mọi trạng thái khác (đều không vượt quá 25%). Điều này cho thấy nhóm khách hàng tốt nhất có hành vi ổn định.
- Khả năng thăng hạng từ các trạng thái trung gian. Từ trạng thái 3, xác suất thăng lên nhóm trung thành (trạng thái 4) là 9,5% và xác suất ở lại trạng thái 3 là 24,6%.

Từ trạng thái 2, xác suất chuyển lên các nhóm giá trị cao hơn là 18,0%. Các nhóm trung gian vì vậy vẫn còn dư địa dịch chuyển đáng kể, là ứng viên tự nhiên cho can thiệp marketing. Hiệu quả cụ thể của từng nhóm sẽ được kiểm chứng định lượng ở mục 4.6.

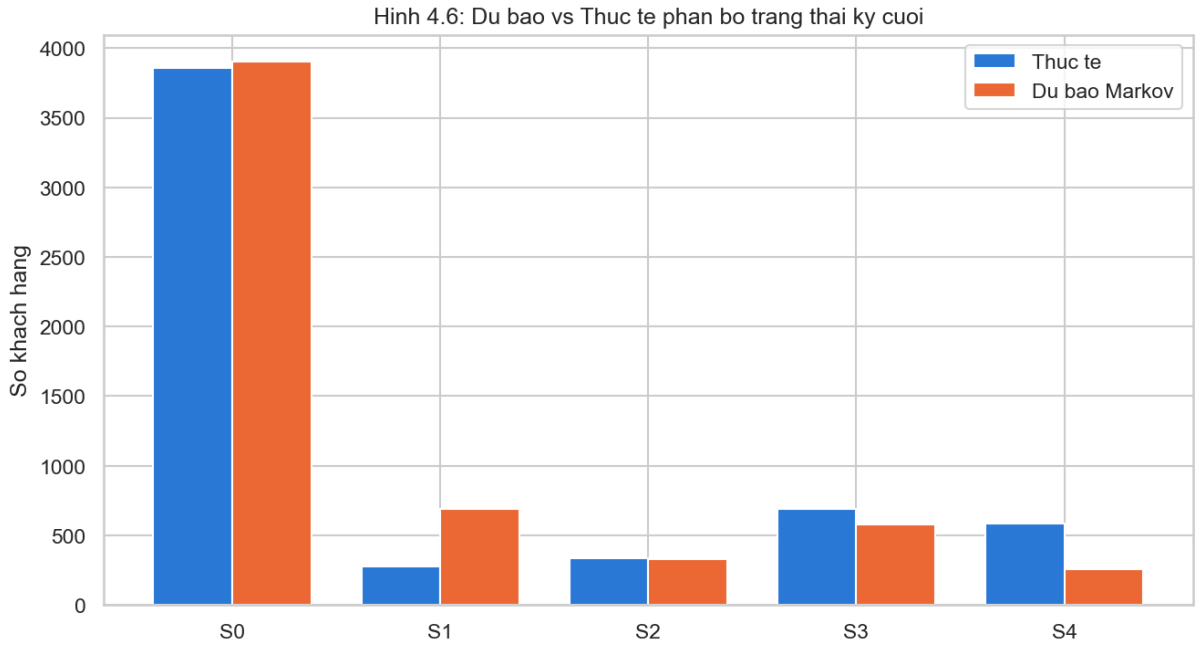
- Khả năng kích hoạt lại từ trạng thái 0. Xác suất một khách hàng đang ở trạng thái 0 quay trở lại hoạt động trong kỳ tiếp theo là 20,8% (79,2% còn lại tiếp tục vắng mặt), cho thấy rời bỏ mang tính khá dai dẳng nhưng không vĩnh viễn, cứ khoảng năm khách hàng ngừng mua thì một người tự quay lại ở kỳ kế tiếp, tạo cơ sở kinh tế cho các chiến dịch kích hoạt lại.

4.4. Kiểm chứng ngoài mẫu

Bảng 4.3 và Hình 4.6 so sánh phân bố trạng thái dự báo bởi mô hình với phân bố thực tế quan sát được ở kỳ kiểm thử.

Trạng thái	Kỳ t	Dự báo	Thực tế	Sai lệch	DB (%)	TT (%)	Δ (%)
S0	3,624	3,901.3	3,857	+44.3	67.81	67.04	+0.77
S1	764	689.1	280	+409.1	11.98	4.87	+7.11
S2	421	328.4	337	−8.6	5.71	5.86	−0.15
S3	693	578.5	691	−112.5	10.06	12.01	−1.96
S4	251	255.8	588	−332.2	4.45	10.22	−5.77

Bảng 4.3: Kết quả kiểm chứng out-of-sample



Hình 4.6: So sánh phân bố trạng thái dự báo và thực tế ở kỳ kiểm thử

Trên toàn bộ năm trạng thái, mô hình dự báo phân bố của kỳ kiểm thử với sai số tuyệt đối trung bình (MAE) khoảng 181 khách hàng và căn bậc hai sai số bình phương

trung bình (RMSE) khoảng 242 khách hàng. Quy về tỷ lệ, sai số trung bình chỉ khoảng 3,15 điểm phần trăm, và khoảng cách biến thiên toàn phần giữa phân bố dự báo với phân bố thực tế là TVD = 0,0788, tức hai phân bố gần như trùng khớp vì TVD nằm trong [0, 1] và càng gần 0 càng tốt. Kết quả này cho thấy ở cấp độ tổng hợp toàn tệp, mô hình Markov dự báo cơ cấu danh mục khách hàng kỳ tiếp theo với độ chính xác cao.

Tuy vậy, một chỉ số tổng hợp tốt ở cấp toàn tệp chưa phản ánh hết bức tranh, vì sai số không phân bố đều giữa các trạng thái. Để tách riêng các nguồn sai số, nghiên cứu phân tích sâu hơn theo hai hướng: kiểm chứng có điều kiện trên nhóm khách còn hoạt động (Bảng 4.3b) và đánh giá ở cấp độ từng khách hàng bằng ma trận nhầm lẫn (Bảng 4.3c).

Kỳ kiểm thử chỉ dài 39 ngày thay vì 61, nên những khách có Recency trong khoảng 39-61 ngày không kịp xuất hiện trong cửa sổ quan sát và bị gán trạng thái 0. Đây là thiên lệch tham gia do độ dài cửa sổ chứ không phải sai số của mô hình, và không thể khử bằng chuẩn hóa cường độ. Bảng 4.3b loại trạng thái 0 ra và chuẩn hóa lại phân phối trên nhóm khách còn hoạt động để tách riêng hai nguồn sai số này.

Trạng thái	Kỳ t	Dự báo	Thực tế	DB (%)	TT (%)	Δ (%)
S1	764	689.1	280	37.21	14.77	+22.44
S2	421	328.4	337	17.74	17.77	−0.04
S3	693	578.5	691	31.24	36.45	−5.21
S4	251	255.8	588	13.81	31.01	−17.20

Bảng 4.3b: Kiểm chứng có điều kiện trên nhóm khách còn hoạt động (loại trạng thái 0, MAE = 215,59 khách, TVD = 0,2244)

Trên nhóm khách còn hoạt động, mô hình sai lệch theo một hướng nhất quán: dự báo thừa 409 khách ở trạng thái 1 và thiếu 332 khách ở trạng thái 4. Nguyên nhân là tính mùa vụ, kỳ kiểm thử rơi vào mùa mua sắm Giáng sinh nên khách dồn lên các trạng thái giá trị cao, trong khi ma trận P được ước lượng từ 10 cặp chuyển tiếp mà phần lớn là các kỳ thường. Đây chính là hạn chế nội tại của xích Markov thuần nhất, đó là giả định xác suất chuyển trạng thái không đổi theo thời gian khiến mô hình về bản chất không thể nắm bắt chu kỳ mùa vụ. Kết luận này củng cố khuyến nghị mở rộng sang xích Markov không thuần nhất hoặc bổ sung biến mùa vụ ở Chương 5.

Ở cấp độ từng khách hàng, dự báo được lấy bằng argmax của hàng tương ứng trong ma trận P. Bảng 4.3c là ma trận nhầm lẫn giữa trạng thái thực tế và trạng thái dự báo trên kỳ kiểm thử.

Thực tế \ Dự báo	S0	S1	S2	S3	S4
S0	3,826	0	0	0	31
S1	275	0	0	0	5
S2	319	0	0	0	18
S3	658	0	0	0	33
S4	424	0	0	0	164

Bảng 4.3c: Ma trận nhầm lẫn ở cấp độ khách hàng (Accuracy = 0,6936, Macro-F1 = 0,2417)

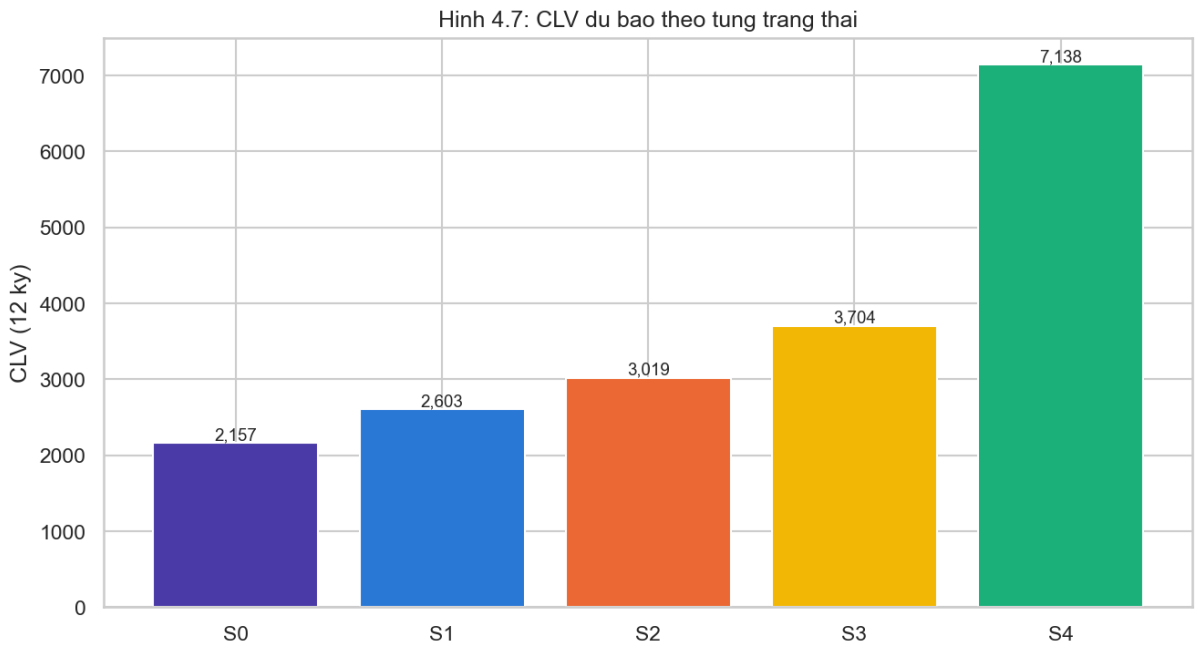
Accuracy đạt 0,6936, nhưng con số này phải đọc cùng mốc đối chiếu: tỷ lệ khách thực tế ở trạng thái 0 là 0,6704, tức một phép đoán tầm thường "mọi khách đều rời bỏ" cũng đạt 67,04%, nên mô hình chỉ vượt mốc đó khoảng 2,3 điểm phần trăm. Ma trận nhầm lẫn giải thích vì sao argmax của bốn hàng đầu trong P đều rơi vào trạng thái 0 và argmax của hàng trạng thái 4 rơi vào chính nó, nên mô hình gần như không bao giờ dự báo các trạng thái 1, 2 và 3, trong khi đó Macro-F1 chỉ đạt 0,2417 phản ánh đúng điều này. Đây là hành vi đã biết của mô hình Markov trên dữ liệu bán lẻ có tỷ lệ rời bỏ cao và là lý do mô hình nên được dùng để dự báo phân bố tổng hợp của danh mục (Bảng 4.3, TVD = 0,0788) chứ không phải để phân loại từng khách hàng riêng lẻ. Muốn dự báo ở cấp cá thể cần một mô hình phân loại có giám sát với tập đặc trưng phong phú hơn.

4.5. Ước lượng giá trị vòng đời khách hàng

Áp dụng công thức ở mục 2.4 với vector phần thưởng R và ma trận chuyển P đã ước lượng, kết quả CLV theo từng trạng thái được trình bày ở Bảng 4.4 và Hình 4.7.

TrangThai	R_moi_ky	CLV_12ky	CLV_vo_han
S0 - Vang mat / Roi bo	0	2,157.35	13,451.86
S1 - Gia tri thap / Da lau	219.96	2,603.44	13,898.00
S2 - Khach moi / Vua mua, gia tri thap	446.22	3,019.29	14,313.89
S3 - Gia tri kha / Nguy co roi bo	793.53	3,703.76	14,998.44
S4 - Trung thanh / Gia tri cao	2,485.36	7,137.94	18,433.04

Bảng 4.4: Giá trị vòng đời khách hàng theo từng trạng thái



Hình 4.7: Giá trị vòng đời khách hàng (CLV) dự báo theo từng trạng thái

Kết quả cho thấy khoảng cách giá trị giữa các phân khúc là đáng kể: CLV (12 kỳ) của khách hàng ở trạng thái cao nhất đạt 7.137,94, gấp khoảng 2,7 lần so với trạng thái hoạt động thấp nhất (trạng thái 1, đạt 2.603,44). Đáng chú ý, khoảng cách CLV tương đối này lại nhỏ hơn khoảng cách về doanh thu mỗi kỳ giữa hai nhóm (khách hàng trạng thái 4 chi tiêu gấp khoảng 11,3 lần trạng thái 1). Nguyên nhân là mô hình Markov đưa vào một "sàn giá trị" từ khả năng dịch chuyển trạng thái và kích hoạt lại, ngay cả khách hàng giá trị thấp hoặc đã rời bỏ vẫn mang giá trị kỳ vọng dương trong tương lai, trong khi khách hàng giá trị cao vẫn đối mặt rủi ro suy giảm và rời bỏ. Vì vậy, thay vì khuếch đại, mô hình thu hẹp chênh lệch tương đối giữa các phân khúc so với doanh thu tức thời, đồng thời vẫn giữ đúng thứ tự xếp hạng giá trị giữa chúng.

Ngay cả khách hàng đang ở trạng thái 0 cũng có CLV dương (2.157,35 cho 12 kỳ), phản ánh xác suất họ được kích hoạt lại trong tương lai. Đây là một ưu điểm quan trọng của mô hình Markov so với các phương pháp phân loại nhị phân churn rằng nó không coi khách hàng rời bỏ là mất hoàn toàn, mà định lượng được giá trị kỳ vọng của khả năng quay lại.

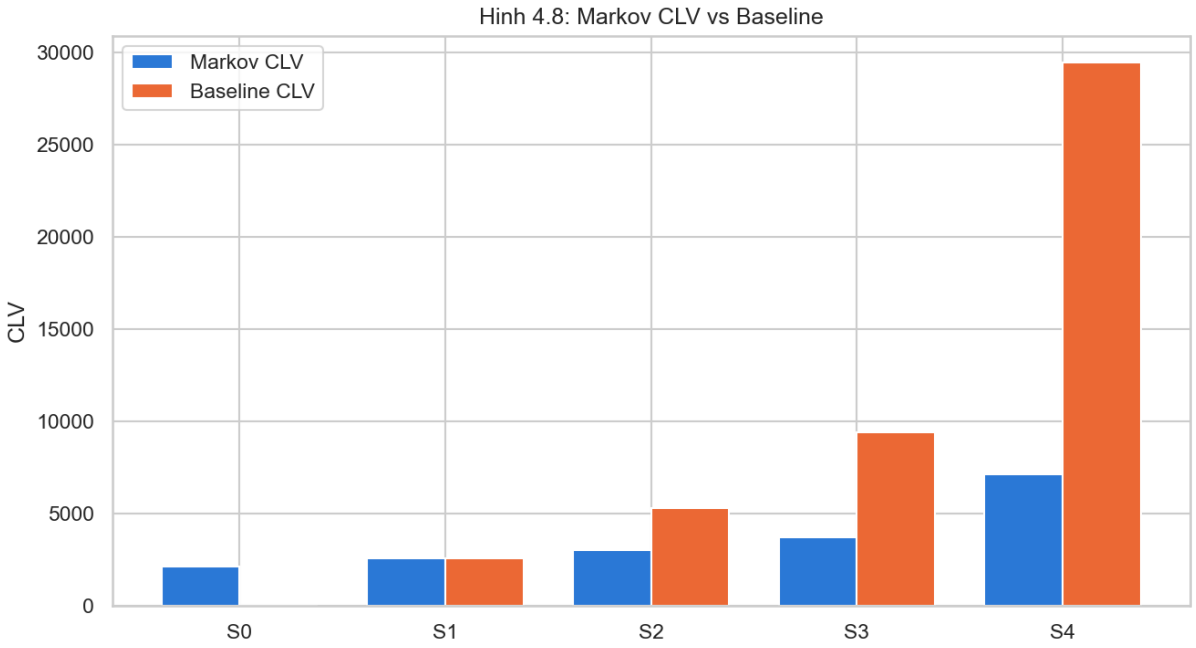
4.6. So sánh với mô hình cơ sở và mô phỏng kịch bản

4.6.1. So sánh với mô hình cơ sở

Bảng 4.5 và Hình 4.8 đối chiếu CLV theo mô hình Markov với mô hình cơ sở giả định khách hàng duy trì vĩnh viễn mức chi tiêu hiện tại.

TrangThai	CLV_Markov	CLV_Baseline	ChenhLech (%)
S0 - Vang mat / Roi bo	2,157.35	-	
S1 - Gia tri thap / Da lau	2,603.44	2,604.14	-0.03
S2 - Khach moi / Vua mua, gia tri thap	3,019.29	5,282.81	-42.85
S3 - Gia tri kha / Nguy co roi bo	3,703.76	9,394.71	-60.58
S4 - Trung thanh / Gia tri cao	7,137.94	29,424.30	-75.74

Bảng 4.5: So sánh CLV Markov với mô hình cơ sở



Hình 4.8: So sánh CLV theo mô hình Markov và mô hình cơ sở (baseline)

Mô hình cơ sở ước lượng CLV cao hơn mô hình Markov ở tất cả các trạng thái hoạt động, với mức chênh lệch trung bình khoảng 44,8%. Đây là kết quả có thể dự đoán về mặt lý thuyết và mang ý nghĩa thực tiễn quan trọng, đó là bằng cách bỏ qua rủi ro rời bỏ và khả năng suy giảm hoạt động, mô hình cơ sở đánh giá quá cao giá trị khách hàng một cách có hệ thống. Nếu doanh nghiệp sử dụng ước lượng này để quyết định ngân sách thu hút khách hàng, họ sẽ có nguy cơ chi vượt mức cần thiết.

Đáng chú ý, mức chênh lệch không đồng đều giữa các trạng thái: chênh lệch lớn nhất rơi vào nhóm khách hàng trung thành/giá trị cao (trạng thái 4, thấp hơn 75,7%), trong khi ở nhóm giá trị thấp/đã lâu (trạng thái 1) hai mô hình gần như trùng nhau (chỉ chênh 0,03%). Nguyên nhân là mô hình cơ sở giả định khách hàng duy trì vĩnh viễn mức chi tiêu hiện tại, nên giả định này sai lệch mạnh nhất ở chính nhóm chi tiêu lớn, đó là

bỏ qua rủi ro suy giảm và rời bỏ của nhóm giá trị cao khiến giá trị bị thổi phồng nhiều nhất. Điều này cho thấy giá trị gia tăng của mô hình Markov thể hiện rõ nhất khi định giá nhóm khách hàng giá trị cao, nhóm mà một ước lượng quá lạc quan dễ dẫn tới chi vượt để thu hút hoặc giữ chân nhất.

4.6.2. Mô phỏng kịch bản can thiệp (what-if)

Một ưu điểm nổi bật của mô hình Markov là khả năng mô phỏng tác động của can thiệp marketing một cách định lượng. Nghiên cứu thực hiện kịch bản giả định là một chiến dịch giữ chân giúp giảm 10 điểm phần trăm xác suất rời bỏ của khách hàng thuộc một trạng thái cụ thể, phần xác suất này được phân bổ lại cho các trạng thái hoạt động theo tỷ lệ hiện có. Sau đó tính lại tổng CLV của toàn bộ tệp khách hàng và so sánh với kịch bản không can thiệp.

CanThiep_vao	TongCLV_moi	GiaTriTang	Tang (%)
S3 - Gia tri kha / Nguy co roi bo	17,878,232	1,054,454	6.27
S4 - Trung thanh / Gia tri cao	17,845,868	1,022,090	6.08
S1 - Gia tri thap / Da lau	17,569,410	745,632	4.43
S2 - Khach moi / Vua mua, gia tri thap	17,268,369	444,591	2.64

Bảng 4.6: Kết quả mô phỏng kịch bản can thiệp (what-if)

Kết quả cho thấy việc can thiệp vào trạng thái 3 (Giá trị khá/Nguy cơ rời bỏ) mang lại giá trị gia tăng lớn nhất, ước tính khoảng 1.054.454 đơn vị tiền tệ, tương đương 6,27% tổng CLV của tệp khách hàng. Trạng thái 4 (Trung thành/Giá trị cao) đứng thứ hai với mức tăng 6,08%, tiếp đến là trạng thái 1 (Giá trị thấp/Đã lâu) với 4,43%. Ngược lại, can thiệp vào trạng thái 2 (Khách mới) chỉ tạo ra mức tăng 2,64%, thấp nhất trong bốn kịch bản.

Phát hiện này có hàm ý thực tiễn trực tiếp và mang tính phản trực giác. Nhóm mang lại hiệu quả can thiệp cao nhất không phải nhóm khách hàng giá trị cao nhất một cách đơn thuần, mà là nhóm có giá trị khá nhưng đang đứng trước nguy cơ rời bỏ, nơi mỗi đồng chi cho giữ chân tác động lên một lượng giá trị lớn đang thực sự lung lay. Nhóm trung thành tuy giá trị cao nhưng xác suất rời bỏ đã thấp nên dư địa cải thiện hẹp hơn trong khi nhóm giá trị thấp và đông nhất dù có nhiều khách để giữ chân lại đóng góp giá trị mỗi khách nhỏ. Do tác động tổng bằng tích của quy mô, dư địa giảm rời bỏ và giá trị mỗi khách, thứ tự ưu tiên can thiệp được quyết định bởi tương tác giữa ba yếu tố này chứ không đơn thuần bởi giá trị hiện tại của từng khách hàng. Đây chính là loại nhận định mà mô hình RFM tĩnh không thể đưa ra.

Cần lưu ý phân bố danh mục dùng để tính tổng CLV được lấy từ kỳ kiểm thử (01/11-09/12/2011), vốn rơi vào mùa mua sắm cuối năm nên tỉ trọng khách ở các trạng thái giá trị cao lớn hơn kỳ thường, do đó tổng CLV toàn tệp (khoảng 16,82 triệu) thiên về lạc quan.

4.6.3. Phân phối dừng và xu hướng dài hạn

Bảng 4.7 so sánh cơ cấu tệp khách hàng hiện tại với phân phối dừng π^* của xích Markov.

TrangThai	TyLeHienTai (%)	PhanPhoiDung (%)
S0 - Vang mat / Roi bo	67.04	69.92
S1 - Gia tri thap / Da lau	4.87	11.56
S2 - Khach moi / Vua mua, gia tri thap	5.86	5.39
S3 - Gia tri kha / Nguy co roi bo	12.01	9.27
S4 - Trung thanh / Gia tri cao	10.22	3.85

Bảng 4.7: Phân phối hiện tại và phân phối dừng của tệp khách hàng

Cơ cấu hiện tại được đo ở kỳ kiểm thử (kỳ 11) dài 39 ngày nên đã phản ánh tương đối hợp lý cấu trúc tệp khách hàng, tỷ trọng khách vắng mặt (trạng thái 0) là 67,04%, phần còn lại phân bổ cho các nhóm hoạt động. So sánh với phân phối dừng π^* cho thấy hệ thống về dài hạn hội tụ về một cơ cấu khá gần với hiện tại: ở trạng thái cân bằng, tỷ trọng khách ở trạng thái 0 là 69,92%, nhóm giá trị thấp/đã lâu (trạng thái 1) chiếm 11,56%, còn nhóm giá trị cao (trạng thái 4) chỉ đạt 3,85%. Đây là một cảnh báo chiến lược, rằng ngay ở trạng thái cân bằng tự nhiên, gần 70% tệp khách hàng rơi vào trạng thái không mua và phần hoạt động bị chi phối bởi nhóm giá trị thấp, trong khi nhóm giá trị cao luôn là thiểu số. Vì vậy, việc duy trì một cơ cấu giàu khách hàng giá trị cao đòi hỏi nỗ lực marketing liên tục chứ không phải là trạng thái mặc định của tệp khách hàng.

4.7. Thảo luận và gợi ý ra quyết định

Tổng hợp các kết quả trên, nghiên cứu rút ra bốn gợi ý ra quyết định cho doanh nghiệp thương mại điện tử:

1. Phân bổ ngân sách theo CLV thay vì theo doanh thu hiện tại. Bảng 4.4 cho thấy chênh lệch CLV tương đối giữa các phân khúc hẹp hơn nhiều so với chênh lệch doanh thu tức thời (khoảng 2,7 lần so với 11,3 lần giữa nhóm cao nhất và thấp nhất), vì mô hình tính đến giá trị kỳ vọng từ khả năng dịch chuyển và kích hoạt lại. Do đó, phân bổ ngân sách chỉ theo doanh thu kỳ hiện tại sẽ đầu tư quá mức

cho nhóm chi tiêu cao và bỏ sót giá trị dài hạn của các nhóm giá trị thấp hoặc đang ngủ đông, nhóm vốn vẫn có xác suất quay lại và đóng góp trong tương lai.

2. Ưu tiên can thiệp vào nhóm có tác động tổng lớn nhất, không phải nhóm giá trị cao nhất. Kết quả mô phỏng ở mục 4.6.2 chỉ ra rằng ngân sách giữ chân mang lại giá trị gia tăng lớn nhất khi tập trung vào nhóm giá trị khá đang có nguy cơ rời bỏ (trạng thái 3: +6,27%), tiếp đến là nhóm trung thành giá trị cao (trạng thái 4: +6,08%) và nhóm giá trị thấp nhưng đông (trạng thái 1: +4,43%), trong khi can thiệp vào nhóm khách mới (trạng thái 2) kém hiệu quả nhất (+2,64%).
3. Không loại bỏ khách hàng đã rời bỏ khỏi danh sách chăm sóc. CLV dương của trạng thái 0 cho thấy các chiến dịch kích hoạt lại (win-back) có cơ sở kinh tế, miễn là chi phí mỗi lượt tiếp cận thấp hơn giá trị kỳ vọng này.
4. Theo dõi ma trận chuyển như một chỉ số sức khỏe định kỳ. Ma trận chuyển có thể được tính lại mỗi kỳ và so sánh với kỳ trước. Sự gia tăng của xác suất chuyển sang trạng thái 0 là tín hiệu cảnh báo sớm về suy giảm sức khỏe tệp khách hàng, xuất hiện trước khi doanh thu thực sự sụt giảm.

Đối với một cửa hàng vận hành trên nền tảng Shopify, các hàm ý này có thể triển khai trực tiếp rằng các trạng thái Markov ánh xạ tự nhiên sang các phân khúc khách hàng trong hệ thống, và các luồng email tự động (automation flow) có thể được thiết kế riêng cho từng trạng thái, với mức đầu tư tương xứng với CLV và dư địa can thiệp của nhóm đó.

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết luận

Nghiên cứu đã xây dựng và kiểm chứng một khung phân tích kết hợp mô hình RFM, thuật toán phân cụm K-means và xích Markov thời gian rời rạc nhằm phân khúc khách hàng và dự báo giá trị vòng đời khách hàng trong bối cảnh thương mại điện tử. Trả lời lần lượt bốn câu hỏi nghiên cứu đặt ra ở mục 1.3:

Thứ nhất, tệp khách hàng của cửa hàng trực tuyến được phân chia thành 4 trạng thái hành vi khác biệt dựa trên chỉ số RFM, cộng thêm một trạng thái đại diện cho khách hàng vắng mặt. Các cụm này ổn định qua các kỳ và có ý nghĩa diễn giải nghiệp vụ rõ ràng.

Thứ hai, ma trận chuyển trạng thái ước lượng được cho thấy quy luật nhất quán: xác suất rời bỏ giảm dần theo mức giá trị khách hàng, từ 60,7% ở nhóm thấp nhất xuống 14,0% ở nhóm cao nhất. Quy luật này trùng khớp với phát hiện của Harish và Malathy (2023) trên cùng loại dữ liệu.

Thứ ba, ở cấp độ tổng hợp toàn tệp, mô hình dự báo phân bố trạng thái kỳ tiếp theo rất sát thực tế, với sai số tuyệt đối trung bình khoảng 181 khách hàng và khoảng cách biến thiên toàn phần TVD chỉ 0,0788 (sai số tỷ lệ khoảng 3,15 điểm phần trăm). Tuy nhiên, phân tích sâu cho thấy độ chính xác này chỉ đúng ở cấp phân bố danh mục: ở cấp độ từng khách hàng, mô hình gần như luôn dự báo trạng thái phổ biến nhất và chỉ nhỉnh hơn phép đoán tầm thường khoảng 2,3 điểm phần trăm, đồng thời tồn tại sai lệch mang tính mùa vụ có hệ thống ở kỳ kiểm thử.

Thứ tư, CLV theo mô hình Markov thấp hơn mô hình cơ sở trung bình khoảng 44,8%, cho thấy việc bỏ qua rủi ro dịch chuyển và rời bỏ dẫn đến đánh giá quá cao giá trị khách hàng một cách có hệ thống, mức đánh giá quá cao này lớn nhất ở chính nhóm khách hàng giá trị cao. Mô phỏng kịch bản chỉ ra rằng can thiệp giữ chân nhóm giá trị khá đang có nguy cơ rời bỏ (trạng thái 3) mang lại giá trị gia tăng tổng lớn nhất (+6,27%), chứ không phải nhóm khách hàng giá trị cao nhất.

Về mặt phương pháp, nghiên cứu khẳng định rằng việc kết hợp một mô hình mô tả đơn giản (RFM) với một mô hình ngẫu nhiên (xích Markov) tạo ra giá trị vượt trội so với từng thành phần riêng lẻ. RFM cung cấp không gian trạng thái có ý nghĩa, còn xích Markov bổ sung chiều thời gian và khả năng định lượng bằng tiền tệ.

5.2. Hạn chế của nghiên cứu

Nghiên cứu tồn tại một số hạn chế cần được thừa nhận một cách minh bạch:

- Giả định Markov bậc một. Mô hình giả định trạng thái tương lai chỉ phụ thuộc trạng thái hiện tại. Trong thực tế, lịch sử hành vi dài hạn có thể mang thông tin bổ sung, một khách hàng vừa từ nhóm cao rơi xuống nhóm trung bình có thể hành xử khác với khách hàng đã ở nhóm trung bình nhiều kỳ liên tiếp.
- Giả định thuần nhất theo thời gian. Ma trận chuyển được giả định không đổi qua các kỳ, do đó không nắm bắt được tính mùa vụ vốn rất rõ rệt trong ngành bán lẻ quà tặng cũng như tác động của các chiến dịch marketing cụ thể. Bằng chứng trực tiếp là sai lệch có hệ thống ở Bảng 4.3b, khi mô hình dự báo thừa khách ở nhóm giá trị thấp và thiếu khách ở nhóm giá trị cao đúng vào kỳ kiểm thử rơi vào mùa lễ cuối năm.
- Hiện tượng hội tụ về phân phối dừng. Như đã nêu ở mục 2.3.4, dự báo nhiều bước sẽ tiến dần về phân phối dừng và mất khả năng phân biệt. Mô hình chỉ đáng tin cậy cho dự báo trong một số ít kỳ liên tiếp.
- Phần thưởng là doanh thu, không phải lợi nhuận. Do dữ liệu không cung cấp giá vốn và chi phí phục vụ, CLV ước lượng được phản ánh dòng doanh thu chứ không phải giá trị lợi nhuận thực. Con số tuyệt đối vì vậy cần được diễn giải thận trọng, mặc dù thứ tự tương đối giữa các phân khúc vẫn có giá trị.
- Tính khái quát hóa. Nghiên cứu chỉ sử dụng dữ liệu của một cửa hàng tại một thị trường trong hai năm. Các tham số cụ thể (số cụm tối ưu, tỷ lệ chuyển trạng thái) không nên được áp dụng máy móc cho các doanh nghiệp khác do sự khác nhau về đặc trưng như sản phẩm, vị trí,… điều có thể chuyển giao là khung phương pháp.
- Kỳ kiểm thử ngắn hơn kỳ huấn luyện. Cửa sổ kiểm thử dài 39 ngày so với 59-62 ngày của các kỳ huấn luyện. Việc quy đổi cường độ đã xử lý phần chênh lệch của Frequency và Monetary nhưng không khử được thiên lệch tham gia, khi khách có Recency trong khoảng 39-61 ngày không kịp xuất hiện và bị gán trạng thái 0. Bảng 4.3b được lập chính là để tách riêng nguồn sai số này.

- Kiểm chứng chỉ dựa trên một kỳ duy nhất. Mọi chỉ số sai số trong nghiên cứu là một quan sát, không có khoảng tin cậy và không tách được thành phần mùa vụ. Một thiết kế kiểm chứng trượt nhiều kỳ (rolling-origin) sẽ cho kết luận vững hơn.
- Chưa so sánh với dự báo tầm thường. Nghiên cứu chưa đối chiếu mô hình Markov với dự báo không đổi hay với phân phối dừng. Ở cấp độ từng khách hàng, kết quả tại Bảng 4.3c cho thấy mô hình chỉ nhỉnh hơn phép đoán mọi khách đều rời bỏ khoảng 2,3 điểm phần trăm, nên phép so sánh này là cần thiết để khẳng định giá trị gia tăng của mô hình.

5.3. Hướng phát triển

Từ các hạn chế trên, nghiên cứu đề xuất bốn hướng phát triển tiếp theo:

1. Mở rộng sang mô hình Markov ẩn. Netzer, Lattin và Srinivasan (2008) cho thấy trạng thái quan hệ khách hàng thực chất là biến ẩn, chỉ quan sát gián tiếp qua hành vi mua. Mô hình Markov ẩn với thuật toán Baum-Welch và Viterbi có thể phát hiện các trạng thái quan hệ tinh tế hơn so với việc phân cụm cơ học trên RFM.
2. Cá nhân hóa ma trận chuyển. Thay vì dùng chung một ma trận cho toàn bộ tệp khách hàng, có thể ước lượng xác suất rời bỏ riêng cho từng cá nhân bằng mô hình sống còn (chẳng hạn Cox Proportional Hazards) rồi hiệu chỉnh ma trận chuyển tương ứng, tạo ra mô hình cá nhân hóa hoàn toàn.
3. Mô hình hóa phần thưởng động. Thay vì dùng doanh thu trung bình cố định cho mỗi trạng thái, có thể dự báo phần thưởng bằng mô hình chuỗi thời gian (chẳng hạn ARIMA), qua đó nắm bắt được xu hướng và tính mùa vụ của dòng doanh thu.
4. Kiểm chứng trên dữ liệu đa nguồn và dữ liệu thực tế. Việc chạy lại toàn bộ khung phương pháp trên các bộ dữ liệu thương mại điện tử khác (chẳng hạn Olist của Brazil) hoặc trên dữ liệu thực từ một cửa hàng Shopify sẽ kiểm tra được tính khái quát của các phát hiện.

DANH MỤC TÀI LIỆU THAM KHẢO

[1] Harish, A. S., & Malathy, C. (2023). Customer Segment Prediction on Retail Transactional Data Using K-Means and Markov Model. Intelligent Automation & Soft Computing, 36(1), 589-600. https://doi.org/10.32604/iasc.2023.032030

[2] Pfeifer, P. E., & Carraway, R. L. (2000). Modeling customer relationships as Markov chains. Journal of Interactive Marketing, 14(2), 43-55.

[3] Netzer, O., Lattin, J. M., & Srinivasan, V. (2008). A hidden Markov model of customer relationship dynamics. Marketing Science, 27(2), 185-204.

[4] Chen, D., Sain, S., & Guo, K. (2012). Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining. Journal of Database Marketing & Customer Strategy Management, 19(3), 197-208.

[5] Cheng, C. J., Chiu, S. W., Cheng, C. B., & Wu, J. Y. (2012). Customer lifetime value prediction by a Markov chain based data mining model: Application to an auto repair and maintenance company in Taiwan. Scientia Iranica, 19(3), 849-855.

[6] Paauwe, J., van der Putten, P., & van Someren, M. (2007). DTMC: An actionable e-customer lifetime value model based on Markov chains and decision trees. Proceedings of the 9th International Conference on Electronic Commerce (ICEC).

[7] Cheng, C. H., & Chen, Y. S. (2009). Classifying the segmentation of customer value via RFM model and RS theory. Expert Systems with Applications, 36(3), 4176-4184.

[8] Aggelis, V., & Christodoulakis, D. (2005). Customer clustering using RFM analysis. Proceedings of the 9th WSEAS International Conference on Computers, 1-5.

[9] Marutho, D., Handaka, S. H., Wijaya, E., & Muljono (2018). The determination of cluster number at K-means using elbow method and purity evaluation on headline news. International Seminar on Application for Technology of Information and Communication.

[10] Hwang, H. S. (2016). A stochastic approach for valuing customers: A case study. International Journal of Software Engineering and Its Applications, 10(3), 67-82.

[11] Mzoughia, M. B., & Limam, M. (2015). An improved customer lifetime value model based on Markov chain. Applied Stochastic Models in Business and Industry, 31(4), 528-535.

[12] UCI Machine Learning Repository (2019). Online Retail II Data Set. Truy cập tại: https://archive.ics.uci.edu/dataset/502/online+retail+ii